

Лабораторная работа 2

Решение задач исследования взаимосвязей в данных

1. Цель лабораторной работы

- получить навыки применения методов корреляционного, дисперсионного анализа и анализа таблиц сопряженности для решения задач АД (анализа данных);
- получить базовые навыки работы в среде R;
- изучить средства R для исследования взаимосвязей признаков (методы корреляционного, рангового корреляционного, дисперсионного анализа, анализа таблиц сопряженности на примере решения конкретной задачи АД).

2. Задание к лабораторной работе

Прочитайте содержательную постановку задачи для вашего варианта. Выберите файл с данными (в формате .csv), соответствующий вашему варианту.

1. Загрузите файл с данными, соответствующий варианту.
2. Проведите корреляционный анализ данных для количественных признаков

2.1. Проверьте гипотезу о соответствии данных модели нормального закона распределения на основе критериев согласия χ^2 (хи-квадрат), Шапиро – Уилка, Крамера – Мизеса, Андерсона – Дарлинга. Проверку выполните для количественных признаков в каждой группе. Для одного из признаков выполните расчет «вручную» (по шагам) на основе критерия хи-квадрат и Крамера – Мизеса. Сопоставьте результаты с расчетом в R. Сопоставьте результаты, полученные при расчете разными критериями. Приведите графическую иллюстрацию (гистограммы распределения значений признаков с наложением функции НЗР).

Сделайте выводы в терминах прикладной задачи о типе распределения данных.

2.2. Оцените степень взаимосвязи между всеми количественными признаками на основе расчета коэффициентов корреляции Пирсона, Спирмена, Кендалла для первой и второй групп. Для одной пары признаков выполните расчет коэффициентов Пирсона и Спирмена «вручную» (по шагам). Сопоставьте результаты с расчетом в R.

2.3. Оцените статистическую значимость коэффициента корреляции Пирсона для одной пары признаков на основе критерия Стьюдента. Выполните расчет в «вручную» (по шагам) и с помощью R. Сопоставьте результаты. Сделайте выводы в терминах прикладной задачи о статистической значимости связи между признаками.

2.4. Оцените степень взаимосвязи между количественными признаками на основе расчета частного коэффициента корреляции Пирсона

для первой и второй групп. Выполните расчет в «вручную» (по шагам) для одной пары признаков. Сопоставьте результаты с расчетом в R. Сделайте выводы в терминах прикладной задачи о статистической значимости связи между признаками.

2.5. Графически представьте матрицу коэффициентов корреляции с наложением тепловой карты.

2.6. Сделайте общие выводы о силе и направлении связи между количественными признаками в терминах решаемой задачи.

3. Оцените степень взаимосвязи между одним из качественных признаков и количественными признаками на основе использования однофакторного дисперсионного анализа (ANOVA) и критерия Краскела-Уоллиса. Выполните расчет «вручную» (по шагам) для одной пары признаков. Сопоставьте результаты с расчетом в R. Сделайте выводы в терминах прикладной задачи о статистической значимости связи между признаками.

4. Выполните анализ таблиц сопряженности. Оцените степень взаимосвязи между качественными признаками на основе критериев χ^2 (Chi-квадрат) и Фишера. Выполните расчет в «вручную» (по шагам) для одной пары признаков по критерию χ^2 . Сопоставьте результаты с расчетом в R. Сделайте выводы в терминах прикладной задачи о статистической значимости связи между признаками.

5. Постройте матричный график с помощью функций пакета ggpairs. При построении графика используйте качественные и количественные признаки. Опишите график, сделайте выводы.

6. Сделайте выводы по работе в произвольной форме.

3. Методические указания к лабораторной работе

Пояснения к п. 2.1.

Для аналитической проверки гипотезы о соответствии нормальному закону распределения могут быть применены критерии согласия: хи-квадрат, Шапиро – Уилка, Крамера – Мизеса, Андерсона – Дарлинга и другие. Функции, реализующие разные критерии согласия, представлены в пакете nortest:

```
install.packages("nortest")  
library(nortest)
```

Пример расчета критерия согласия хи-квадрат для проверки гипотезы о нормальном законе распределения значений признака Experience – стаж в первой группе:

```
data1<-subset(data, data$Group=="1")  
pearson.test(data1$Experience)
```

В результате:

```
pearson chi-square normality test  
data: data1$Experience  
P = 16.22, p-value = 0.09351
```

Пример расчета критерия согласия Андерсона-Дарлинга для проверки гипотезы о нормальном законе распределения значений признака Experience – стаж в первой группе:

```
ad.test(data1$Experience)
```

В результате:

```
Anderson-Darling normality test  
data: data1$Experience  
A = 0.71683, p-value = 0.05957
```

Пример расчета критерия согласия Шапиро-Уилка для проверки гипотезы о нормальном законе распределения значений признака Experience – стаж в первой группе:

```
shapiro.test(data1$Experience)
```

В результате:

```
shapiro-wilk normality test  
data: data1$Experience  
W = 0.97717, p-value = 0.07981
```

Пример расчета критерия согласия Крамера – Мизеса для проверки гипотезы о нормальном законе распределения значений признака Experience – стаж в первой группе:

```
cvm.test(data1$Experience)
```

В результате:

```
Cramer-von Mises normality test  
data: data1$Experience  
W = 0.12015, p-value = 0.05862
```

Гипотеза о нормальном распределении значений признака «стаж» в первой группе не отвергается при уровне значимости 0,05 ($p\text{-value} > 0,05$) по всем критериям согласия.

Построение гистограммы с наложением функции плотности нормального закона распределения:

```
install.packages("rcompanion")
library(rcompanion)
par(mfrow = c(1,2))
plotNormalHistogram(data$Age, xlab="возраст", ylab="Количество
наблюдений", length = 1000, breaks = seq(min(data$Age), max(data$Age),
length.out = 7))
plotNormalHistogram(data$Experience, xlab="стаж", ylab="Количество
наблюдений", length = 1000, breaks = seq(min(data$Experience), max(data$Experience),
length.out = 7))
```

В результате:




Рисунок 1– Пример гистограмм с наложением функции НЗР

Пояснения к п. 2.2.

В R можно рассчитывать разные коэффициенты корреляции для оценки взаимосвязи между количественными и порядковыми признаками, включая коэффициенты Пирсона, Спирмена, Кендалла, частные, полихорические и многорядные.

Линейный коэффициент корреляции Пирсона (Pearson product moment correlation) отражает степень линейной связи между двумя количественными признаками. Коэффициент ранговой корреляции Спирмена (Spearman's Rank Order correlation) – мера связи между двумя ранжированными признаками. Тау

Кендалла (Kendall's Tau) – также непараметрический коэффициент ранговой корреляции.

Функция `cor()` позволяет вычислить все три коэффициента, а функция `cov()` рассчитывает ковариации. У этих функций есть много параметров, но упрощенный формат вычисления корреляций таков:

`cor(x, use= , method= )`.

Эти параметры описаны в таблице 1. Значения опций по умолчанию: `use="everything"` и `method="pearson"`.

Таблица 1 – Параметры (опции) функций `cor()` и `cov()`

Опция	Описание
<code>x</code>	Матрица или таблица данных
<code>use=</code>	Упрощает работу с пропущенными данными. Может принимать следующие значения: <code>all.obs</code> (предполагается, что пропущенные значения отсутствуют; их наличие вызовет сообщение об ошибке), <code>everything</code> (любая корреляция, включающая строку с пропущенным значением, не будет вычисляться – обозначается как <code>missing</code>), <code>complete.obs</code> (учитываются только строки без пропущенных значений) и <code>pairwise.complete.obs</code> (учитываются все полные наблюдения для каждой пары переменных в отдельности)
<code>method=</code>	Определяет тип коэффициента корреляции. Возможные значения – <code>pearson</code> , <code>spearman</code> или <code>kendall</code>

Ниже приведен пример вычисления коэффициентов корреляции между количественными признаками, хранящимися в таблице `data1`.

```
M <- data1[,unlist(lapply(data1, is.numeric))]
N1<-cor(M, use="pairwise.complete.obs")
N2<-cor(M, use="pairwise.complete.obs",method="spearman")
N3<-cor(M, use="pairwise.complete.obs",method="kendall")
View(N1)
View(N2)
View(N3)
```

Первая команда выбирает из таблицы `data1` количественные признаки и сохраняет их в таблице `M`. Вторая команда вычисляет матрицу коэффициентов корреляции Пирсона между всеми количественными признаками, третья команда – матрицу коэффициентов корреляции Спирмена, четвертая команда – матрицу коэффициентов корреляции Кендалла.

Пояснения к п. 2.3.

Оценка значимости коэффициента корреляции Пирсона реализуется в функции `cor.test()`, `conf.level` – уровень доверительной вероятности, по умолчанию – 0.95.

Пример:

```
cor.test(data1$Experience,data1$Age, conf.level = 0.9)
```

В результате:

```
      Pearson's product-moment correlation

data:  data1$Experience and data1$Age
t = 2.0601, df = 98, p-value = 0.04204
alternative hypothesis: true correlation is not equal to 0
90 percent confidence interval:
 0.03959907 0.35717056
sample estimates:
      cor 
0.203738
```

В результате выполнения функции выдается расчетное значение критической статистики (t), число степеней свободы (df), p-значение (p-value) и 90% доверительный интервал, в который попадает истинное значение коэффициента корреляции Пирсона.

Оценка значимости коэффициентов корреляции Спирмена и Кендалла реализуется в функции `cor.test()` при указании параметра `method`.

Пример:

```
cor.test(data1$Experience,data1$Age, method="spearman")
cor.test(data1$Experience,data1$Age, method="kendall")
```

Результат:

```
      kendall's rank correlation tau

data:  data1$Experience and data1$Age
z = 1.7807, p-value = 0.07497
alternative hypothesis: true tau is not equal to 0
sample estimates:
      tau 
0.1311596
```

Пояснения к п. 2.4.

Для вычисления коэффициентов частной корреляции Пирсона можно использовать функцию `pcor()` из пакета `ppcor`.

```
install.packages("ppcor")  
library(ppcor)
```

Пример вычисления матрицы частных коэффициентов корреляции Пирсона для признаков 4-8 таблицы data1:

```
M1 <- data1[c(4:8)]  
C1<-pcor(M1)
```

Вывод матрицы коэффициентов корреляции и р-значения для оценки статистической значимости коэффициента:

```
View(C1$estimate)  
View(C1$p.value)
```

Матрицу частных коэффициентов корреляции также можно рассчитать на основе коэффициентов Спирмена и Кендалла:

```
C2<-pcor(M1, method="spearman")  
C3<-pcor(M1, method="kendall")
```

Пояснения к п. 2.5.

Для графического представления степени взаимосвязей между признаками необходимо установить пакет corrplot:

```
install.packages("corrplot")  
library(corrplot)  
  
col <- colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD",  
"#4477AA"))  
corrplot(N1, method="color", col=NULL,  
         type="upper", order="hclust",  
         addCoef.col = "black", tl.col="black", tl.srt=45,  
         sig.level = 0.01, insig = "blank",  
         diag=FALSE  
)
```

В результате будет выведена корреляционная матрица Пирсона, в которой значения коэффициентов выделены цветами в соответствии с их величиной (рисунок 2).



Рисунок 2 – Пример графического представления матрицы коэффициентов корреляции Пирсона

Более подробно о возможностях визуализации корреляций с помощью пакета `corrplot` можно посмотреть по ссылке: <http://www.sthda.com/english/wiki/visualize-correlation-matrix-using-correlogram>.

Пояснения к п. 3.

Для оценки взаимосвязи между качественным признаком и количественным признаком (в случае нормального распределения значений) используется однофакторный одномерный дисперсионный анализ (ANOVA).

Функция `aov()` реализует однофакторный одномерный дисперсионный анализ:

```
aov_model <- aov(data$Experience ~ data$Group, data=data)
summary(aov_model)
```

В примере оценивается взаимосвязь между стажем и группой.

В результате выполнения функции выдается расчетное F-значение (F value), число степеней свободы (Df) и p-значение (Pr(>F))

```

      Df Sum Sq Mean Sq F value Pr(>F)
data$Group    1  765.6    765.6   1448 <2e-16 ***
Residuals  198  104.7     0.5
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Гипотеза о статистической незначимости отличий в распределении признака «стаж» по группам отвергается при уровне значимости 0,05 (p-value <<0,05). Значения стажа в группах отличаются статистически значимо.

Для оценки взаимосвязи между качественным признаком и количественным признаком (в случае, если распределение значений признака не подчиняется нормальному закону распределения) используется критерий Краскела-Уоллиса:

```
kruskal.test(data$Experience ~ data$Group, data= data)
```

В результате выдается расчетное значение критической статистики критерия (chi-squared) и p-value:

```

kruskal-wallis rank sum test

data: data$Experience by data$Group
kruskal-wallis chi-squared = 149.38, df = 1, p-value < 2.2e-16

```

Гипотеза о статистической незначимости отличий в распределении признака «стаж» по группам отвергается при уровне значимости 0,05 (p-value <<0,05). Значения стажа в группах отличаются статистически значимо.

Пояснения к п. 4.

В R реализованы различные способы построения и анализа таблиц сопряженности для исследования взаимосвязей между качественными (классификационными) признаками. В таблице 2 приведены основные функции для построения таблиц сопряженности.

Таблица 2 – Основные функции для работы с таблицами сопряженности

Функция	Описание
<code>table(var1, var2, ..., varN)</code>	Создает N-мерную таблицу сопряженности для N категориальных переменных (факторов)
<code>xtabs(formula, data)</code>	Создает N-мерную таблицу сопряженности на основе формулы и матрицы или таблицы данных
<code>prop.table(table, margins)</code>	Представляет значения таблицы в виде долей от значений крайнего поля таблицы, задаваемого параметром <i>margins</i>
<code>margin.table(table, margins)</code>	Суммирует значения таблицы по строкам или столбцам (определяется параметром <i>margins</i>)
<code>addmargins(table, margins)</code>	Вычисляет описательные статистики <i>margins</i> (суммы по умолчанию) для таблицы
<code>ftable(table)</code>	Создает компактную «плоскую» таблицу сопряженности

Для построения простой таблицы сопряженности между двумя качественными признаками используется команда:

```
table<-table(data$name_1, data$name_2)
View(table)
```

Для вычисления значений в процентах используется команда:

```
prop.table(table)
```

Для вычисления сумм по строкам и столбцам таблицы:

```
addmargins(table)
```

Для исследования взаимосвязей между качественными признаками реализованы различные тесты и коэффициенты корреляции. Один из самых часто используемых на практике – хи-квадрат критерий (тест) Пирсона. Критерий проверяет основную гипотезу об отсутствии взаимосвязи между двумя качественными признаками (например, качество документирования и пол):

```
chisq.test(table(data$Quality,data$Gender))
```

В результате выполнения функции выдается расчетное значение критической статистики критерия (X-squared), число степеней свободы (df) и р-значение:

Pearson's Chi-squared test

```
data: table(data$Quality, data$Gender)
X-squared = 44.943, df = 3, p-value = 9.514e-10
```

Также реализован критерий Фишера для проверки основной гипотезы об отсутствии взаимосвязи между двумя качественными признаками (например, качество документирования и пол):

```
fisher.test(table(data$Quality, data$Gender))
```

В результате выполнения команды выдается р-значение и отношение шансов (отношение шансов вычисляется только для бинарных признаков и таблиц сопряженности 2 на 2). В этом случае не выводится так как признак «качество документирования» имеет четыре градации:

Fisher's Exact Test for Count Data

```
data: table(data$Quality, data$Gender)
p-value = 6.838e-11
alternative hypothesis: two.sided
```

Ниже приведен фрагмент кода, который выполняет расчет по критерию хи-квадрат для всех качественных признаков, включенных в таблицу data, и выводит р-значение для каждой пары признаков:

```
#Получаем имена только качественных признаков
factor_names <- names(data[,unlist(lapply(data, is.factor))])

#Создаем таблицу для значений p.value
chi_results <- matrix(NA,nrow = length(factor_names),ncol=length(factor_names))
colnames(chi_results) <- c(factor_names)
rownames(chi_results) <- c(factor_names)

#Проводим Chi.test и заполняем таблицу
for (col_name in factor_names){
  for (col_name2 in factor_names){
    chi_results[col_name,col_name2] <- chisq.test(table(data[,col_name],data[,col_name2]))$p.value
  }
}
chi_results
```

В результате:

	Group	Gender	Satisfaction_1	Quality
Group	1.543120e-44	5.590606e-01	9.198513e-06	1.945654e-02
Gender	5.590606e-01	1.761964e-44	1.226268e-03	9.513755e-10
Satisfaction_1	9.198513e-06	1.226268e-03	2.781632e-85	1.257279e-05
quality	1.945654e-02	9.513755e-10	1.257279e-05	2.094185e-123

Пояснения к п. 5.

Разные варианты матричных графиков могут быть построены с помощью функции `ggpairs()` из библиотеки `GGally`. Код для построения матричных графиков между исследуемыми признаками следующий:

```
install.packages("GGally")
install.packages("ggplot2")
library(GGally)
library(ggplot2)
#Пример 1
ggpairs(data, columns = 2:5, aes(color = Group,alpha = 0.5))
#Пример 2
ggpairs(data, columns = c(2,6:10), aes(color = Group,alpha = 0.5))
```

Преимущество использования функции `ggpairs()` по сравнению с базовой функцией `pairs()` заключается в том, что построенный матричный график содержит сравнительно больше информации о распределении и взаимосвязях между признаками. На матричном графике отображена следующая информация (рисунок 3, 4):

- графики плотности распределения вероятностей для количественных признаков для каждого класса и столбиковые диаграммы для качественных признаков;
- диаграммы рассеяния между парами количественных признаков с выделением цвета класса;
- диаграммы размаха для каждого класса для количественных признаков;
- гистограммы распределения количественных признаков по классам;
- значения коэффициентов корреляции Пирсона с оценкой их статистической значимости для пар количественных признаков, рассчитанные по всем данным и с разделением по классам.



Рисунок 3 – Матричный график (Пример 1)




Рисунок 4 – Матричный график (Пример 2)

4. Отчет о работе

Содержание

1. Постановка задачи АД.

2. Корреляционный анализ данных

- проверка гипотезы о НЗР распределения значений признаков в первой и второй группе на основе критериев согласия;
- гистограммы распределения значений признаков с наложением функции НЗР;
- выводы о типе распределения данных;
- матрицы коэффициентов корреляции Пирсона, Спирмена, Кендалла по группам; выводы о взаимосвязях;
- проверка гипотезы о статистической значимости коэффициента корреляции Пирсона; выводы;
- матрицы частных коэффициентов корреляции Пирсона по группам; выводы о взаимосвязях;
- матричный график коэффициентов корреляции Пирсона с наложением тепловой карты.

3. Исследование взаимосвязей между количественными и качественными признаками

- результаты расчета дисперсионного анализа, критерия Краскела-Уоллиса;
- выводы о взаимосвязях.

4. Исследование взаимосвязей между качественными признаками

- результаты расчета критерия хи-квадрат; критерия Фишера;
- выводы о взаимосвязях.

5. Матричные графики, построенные функцией `ggpairs()`; описание и анализ графиков.

6. Общие выводы о силе и направлении связи между исследуемыми признаками в терминах решаемой задачи для первой и второй групп).

7. Выводы по работе в произвольной форме.

8. Приложение. Полный код на R.

5. Вопросы к работе

1. Приведите математическую постановку задачи исследования взаимосвязей между признаками. В каких предметных областях решается задача? Приведите примеры.

2. Какие методы используются для исследования закона распределения данных? В чем различия параметрических и непараметрических критериев согласия?

3. Для чего исследуются законы распределения признаков при решении задачи исследования взаимосвязей?

4. В чем различия простой и сложной гипотезы о проверке согласия теоретического и выборочного закона распределения данных?

5. Опишите основные критерии согласия для проверки гипотезы о нормальном распределении выборочных данных: алгоритм использования критерия; критическая статистика критерия; сравнительная мощность критерия.

6. Что понимается под корреляционным анализом данных? Какие основные задачи решаются в рамках корреляционного анализа данных?

7. Что понимается под ранговым корреляционным анализом данных? Какие основные задачи решаются в рамках рангового корреляционного анализа данных?

8. От каких факторов зависит выбор характеристики взаимосвязи?

9. Какие характеристики взаимосвязи используются на каждой из шкал измерения значений признака (количественная, порядковая, классификационная)?

10. Опишите основные характеристики взаимосвязи, используемые на разных шкалах: суть; основная расчетная формула; свойства; ограничения использования; критерий для проверки гипотезы о статистической незначимости характеристики взаимосвязи; расчет в R.

11. Что понимается под дисперсионным анализом данных? Приведите постановку задачи и алгоритм применения однофакторного одномерного дисперсионного анализа. Каковы условия применения дисперсионного анализа данных?

12. Критерий Краскела-Уоллиса. Алгоритм критерия, условия применения, расчет в R, интерпретация результатов в терминах решаемой задачи.

13. Какие измерители связи применяются для измерения степени тесноты связи между качественными переменными? Их расчет в R, оценка статистической значимости и интерпретация результатов в терминах решаемой задачи.

14. Как построить разные варианты матричных графиков в R? Какие пакеты и функции используются?

Литература

1. Альсова О. К. Методы и модели решения задачи классификации. Основные этапы : учеб. пособие / О. К. Альсова, Н. А. Зеленчук. - Новосибирск: НГТУ, 2024. - 88 с. - ISBN 978-5-7782-5280-6.
2. Анализ данных: учебник для вузов / под редакцией В. С. Мхитаряна. — Москва : Издательство Юрайт, 2026. — 448 с. — (Высшее образование). — ISBN 978-5-534-19964-2. — Текст : электронный // Образовательная платформа Юрайт [сайт]. — URL: <https://urait.ru/bcode/560311> (дата обращения: 15.01.2026).
3. Миркин, Б. Г. Базовые методы анализа данных : учебник и практикум для вузов / Б. Г. Миркин. — 3-е изд., перераб. и доп. — Москва :

- Издательство Юрайт, 2026. — 297 с. — (Высшее образование). — ISBN 978-5-534-19709-9. — Текст : электронный // Образовательная платформа Юрайт [сайт]. — URL: <https://urait.ru/bcode/560414> (дата обращения: 15.01.2026).
4. Гмурман, В. Е. Теория вероятностей и математическая статистика : учебник для вузов / В. Е. Гмурман. — 12-е изд. — Москва : Издательство Юрайт, 2026. — 479 с. — (Высшее образование). — ISBN 978-5-534-00211-9. — Текст : электронный // ЭБС Юрайт [сайт]. — URL: <https://urait.ru/bcode/449646>
 5. Кабаков Р. И. R в действии / И. Р. Кабаков ; пер. с англ. А. Н. Киселева. — Москва : ДМК Пресс, 2023. — 768 с.
 6. Мастицкий С. Э. Статистический анализ и визуализация данных с помощью R / С. Э. Мастицкий, В. К. Шитиков. — Москва : ДМК Пресс, 2023. — 497 с.
 7. Официальный сайт R [Электронный ресурс]. — Режим доступа: <https://www.r-project.org> (дата обращения: 15.01.2026).
 8. Репозиторий пакетов R [Электронный ресурс]. — URL: <https://cran.r-project.org/web/packages> (дата обращения: 15.01.2026).
 9. Дж. Д. Лонг и Пол Титор Книга рецептов: Проверенные рецепты для статистики, анализа и визуализации данных / пер. с англ. Д. А. Беликова. — М.: ДМК Пресс, 2020. — 510 с.
 10. Шитиков В. К., Мастицкий С. Э. (2017) Классификация, регрессия, алгоритмы Data Mining с использованием R. - Электронная книга, адрес доступа: <https://github.com/ranalytics/data-mining>

Постановка задачи АД.

Варианты 1-5. Изучаются показатели работы программистов крупной организации. Для проведения статистического исследования предоставлена БД, включающая 200 записей (наблюдений), каждая из которых содержит описание показателей деятельности программиста. Все программисты разделены на две равные группы (100 записей в каждой группе). Рассматриваются следующие показатели (признаки) для каждого программиста:

- Group – группа (1, 2);
- Gender - пол (1-м, 2-ж);
- Age - возраст;
- Experience - стаж работы;
- % of on-time developments - процент разработок, выполненных в срок в рамках бюджета с требуемым функционалом (за год);
- Number of user-reported bugs - количество ошибок, выявленных пользователем (за год);
- Customer satisfaction score (score) - степень удовлетворенности заказчика (баллы);

- Customer satisfaction score (level) - степень удовлетворенности заказчика (качественная оценка);
- Documentation quality - качество документирования (1 – низкое, 2 – среднее, 3 – выше среднего, 4 – высокое).

Необходимо провести предварительный разведочный анализ данных, графический анализ данных с целью описания характера распределения и структуры данных по выделенным группам программистов, сравнения показателей по группам.

Варианты 6-10. Исследуются покупатели Интернет-магазина. Для проведения статистического исследования предоставлена БД, включающая 200 записей (наблюдений), каждая из которых содержит описание покупателя магазина. Все покупатели разделены на две равные группы (100 записей в каждой группе). Рассматриваются следующие показатели (признаки) для каждого покупателя:

- Group – группа (1, 2);
- Gender - пол (1-м, 2-ж);
- Age - возраст;
- Number of purchases - количество покупок за год;
- Average purchase price - средняя стоимость покупок за год;
- Average number of pages - среднее число страниц, просмотренных за визит;
- Number of support requests - количество обращений в службу поддержки за год;
- Participation in online surveys – участие в Интернет-опросах (1 – никогда, 2 – редко, 3 – часто, 4 – постоянно);
- Service satisfaction score (score) – степень удовлетворенности услугами (баллы);
- Service satisfaction score (level) – степень удовлетворенности услугами (качественная оценка)

Необходимо провести предварительный разведочный анализ данных, графический анализ данных с целью описания характера распределения и структуры данных по выделенным группам покупателей, сравнения покупателей по группам.

Варианты 11-15. Исследуется рынок потребителей услуги «Подключение к сети Интернет». Для проведения статистического исследования предоставлена БД, включающая 200 записей (наблюдений), каждая из которых содержит описание потребителя услуг. Все потребители разделены на две равные группы (100 записей в каждой группе). Рассматриваются следующие показатели (признаки) для каждого потребителя:

- Group – группа (1, 2);
- Gender - пол (1-м, 2-ж);

- Age - возраст;
- Work experience - стаж работы (время использования услуги);
- Average income - средний доход;
- Professional specialization - профессиональная специализация (насколько часто используется сеть Интернет в профессиональной деятельности): 1 – не использую; 2 – крайне редко; 3 – ежедневно, 4 – постоянно;
- Average number of pages - среднее количество просматриваемых страниц в месяц;
- Activity level (score) - степень активности (участие в Интернет-опросах, баллы);
- Activity level (level) - степень активности (участие в Интернет-опросах, качественная оценка);

Необходимо провести предварительный разведочный анализ данных, графический анализ данных с целью описания характера распределения и структуры данных по выделенным группам потребителей, сравнения потребителей по группам.